Cahier des charges — Projet NLP M2

Sep 26, 2026 · @youcef

1. Contexte et objectif

Le projet construit **ComplaintLens**, une plateforme NLP de bout en bout qui analyse les plaintes clients réelles déposées auprès du régulateur financier américain (CFPB) : routage automatique, extraction d'entités, détection de thèmes, synthèse, et assistant RAG ancré dans la réglementation.

Problématique. Une banque reçoit des milliers de réclamations en texte libre. Comment les trier (produit, motif), en extraire les faits (montants, dates, organismes), repérer les signaux faibles (nouveaux thèmes, fraudes émergentes), prédire l'issue (réponse de l'entreprise, remboursement) et produire une réponse argumentée citant le texte réglementaire applicable ?

Pourquoi ce corpus. Il est réel, massif (plusieurs millions de plaintes dont plus d'un million avec récit libre), étiqueté nativement (produit, sous-produit, motif, sous-motif, réponse de l'entreprise), horodaté sur 15 ans, et désormais **figé** : la publication des récits a cessé le 14 août 2026, ce qui garantit un corpus stable et reproductible. Le domaine (banque de détail, crédit, recouvrement) est directement transposable au contexte BNP.

Objectifs mesurables.

- Classifier le produit (≈ 10 classes) avec un macro-F1 ⩾ 0,85 et le motif (≈ 80+ classes, hiérarchique) avec un macro-F1 ⩾ 0,60.
- Extraire 8 types d'entités métier avec un F1 entité (seqeval) ⩾ 0,75 sur un jeu annoté manuellement.
- Produire des résumés évalués (ROUGE, BERTScore, fidélité factuelle) et un RAG avec ⩾ 80 % de réponses correctement sourcées sur un jeu de questions construit.
- Livrer une application déployée, monitorée, avec rapport scientifique de 30–40 pages.

2. Sources de données

La source principale est l'**archive FOIA des récits du CFPB** : 21 fichiers ZIP couvrant les plaintes reçues du 1er décembre 2011 au 14 août 2026, récits inclus. Depuis août 2026, la base publique ne publie plus les récits : il faut passer par cette archive, pas par le CSV courant.

Source	Contenu	Rôle dans le projet	Accès
CFPB Narratives Archive	Plaintes 2011–2026 avec récit libre, 21 exports ZIP	Corpus principal : toutes les tâches	Téléchargement direct, domaine public US
CCDB Field reference	Dictionnaire des champs (Product, Issue, Sub-issue, Company response, Timely response, Tags, State…)	Schéma, labels supervisés	Doc publique
CCDB complaints.csv.zip	Base courante sans récits	Contrôle de cohérence, métadonnées récentes	Téléchargement direct
DataLumos mirror (ICPSR)	Copie archivée de la base (mars 2026), DOI citable	Sauvegarde, citation académique	Compte gratuit
eCFR	Texte des réglementations fédérales (Title 12 : Reg Z, Reg E, Reg F, Reg V…)	Base documentaire du RAG	API REST publique
Ask CFPB	FAQ consommateurs (questions/réponses officielles)	Jeu de QA pour évaluer le RAG, corpus d'adaptation	Scraping respectueux (robots.txt)

Caractéristiques du texte. Les données personnelles sont masquées par le CFPB (séquences `XXXX`, montants `{$1500.00}`) : le prétraitement doit gérer ce bruit et c'est aussi une opportunité d'étudier l'anonymisation. Les récits font de quelques phrases à plusieurs milliers de mots (longue traîne → troncature, chunking, modèles longs).

Sous-échantillonnage. Le corpus complet dépasse les ressources d'un M2. Figer un sous-corpus de travail de 300 000 plaintes (stratifié par produit et année) + un split temporel : train ⩽ 2023, validation 2024, test 2025–2026. Le split temporel est obligatoire pour mesurer la dérive.

Annotation manuelle à produire. Aucune étiquette NER ni résumé de référence n'existe. Livrables d'annotation : 1 500 récits annotés en entités (Label Studio ou Doccano), 300 résumés de référence, 200 paires question/réponse sourcées pour le RAG. Mesurer l'accord inter-annotateurs (kappa de Cohen) sur 10 % en double annotation.

3. Périmètre : cartographie des concepts NLP

Le projet est découpé en 10 lots ; chaque concept NLP majeur est couvert par au moins un lot et implémenté, pas seulement cité.

Famille de concepts	Concepts implémentés	Lot
Prétraitement	Normalisation Unicode, nettoyage des masques `XXXX`, segmentation en phrases, tokenisation (mots, BPE, WordPiece, SentencePiece), stopwords, lemmatisation vs stemming, POS tagging, parsing en dépendances, détection de langue	L1
Linguistique de corpus	Loi de Zipf, loi de Heaps, n-grammes, collocations (PMI), lisibilité (Flesch), statistiques de longueur	L1
Représentations creuses	Bag-of-words, TF-IDF, n-grammes de caractères, hashing trick, sélection de variables (χ^2)	L2
Représentations denses statiques	Word2Vec (CBOW, skip-gram, negative sampling) entraîné sur le corpus, GloVe, FastText (sous-mots, OOV), analogies, visualisation UMAP/t-SNE	L3
Modèles de langue	N-grammes avec lissage (Kneser-Ney), perplexité, LM neuronal, masked LM vs causal LM	L3, L5
Deep learning séquentiel	CNN texte, BiLSTM/GRU, attention additive, CRF	L4, L6
Transformers	Self-attention, multi-head, positional encoding, fine-tuning encodeur (BERT, RoBERTa, DeBERTa, ModernBERT), domain-adaptive pretraining (MLM continu sur le corpus), modèles longs	L5
Classification	Binaire, multi-classe, hiérarchique (Product → Issue → Sub-issue), multi-label (Tags), déséquilibre (class weights, focal loss), calibration	L2, L4, L5

Famille de concepts	Concepts implémentés	Lot
Extraction d'information	NER (BIO, CRF, BiLSTM-CRF, transformer token classification), extraction de relations, normalisation d'entités (montants, dates), anonymisation/PII	L6
Apprentissage faiblement supervisé	Weak supervision (règles + labeling functions), active learning, zero-shot / few-shot via LLM, distillation LLM → petit modèle	L6, L9
Modélisation thématique	LDA, NMF, BERTopic, cohérence (c_v, NPMI), topics dynamiques dans le temps	L7
Sémantique et similarité	Sentence embeddings (SBERT), recherche sémantique, détection de quasi-doublons (MinHash/LSH), clustering	L7, L8
Analyse de sentiment et émotion	Lexiques (VADER), modèles supervisés transférés, analyse par aspect (ABSA)	L4
Génération	Résumé extractif (TextRank) et abstractif (BART/T5, LLM), stratégies de décodage (greedy, beam, top-k, top-p, température), hallucination	L8
LLM et RAG	Prompting (zero/few-shot, CoT), structured output (JSON), chunking, embeddings, index vectoriel (FAISS), BM25, recherche hybride, reranking (cross-encoder), fine-tuning PEFT (LoRA/QLoRA), LLM-as-a-judge	L9
Explicabilité et robustesse	LIME, SHAP, Integrated Gradients, attention maps, tests comportementaux (CheckList), attaques adversariales, dérive temporelle	L10
Éthique	Biais (état, tag Older American/Servicemember), fairness metrics, confidentialité, model cards, datasheets	L10
MLOps	Suivi d'expériences, versioning données/modèles, serving API, quantization, monitoring	Transverse

Hors périmètre. Parole (ASR/TTS), traduction automatique complète, pré-entraînement d'un LLM from scratch.

4. Spécifications par lot

Chaque lot livre du code testé, un notebook d'analyse et une section du rapport. Les baselines sont obligatoires : aucun modèle complexe n'est accepté sans comparaison à un modèle simple.

L0 — Ingestion et data engineering

- Télécharger les 21 ZIP, vérifier les checksums, convertir en Parquet partitionné par année.
- Harmoniser les taxonomies : les libellés Product/Issue ont changé en 2017 et 2023. Construire une table de mapping ancien → nouveau et la documenter.
- Dédupliquer (Complaint ID, puis quasi-doublons MinHash), filtrer les récits vides, figer le sous-corpus et les splits (seed fixée, versionné DVC).
- Livrable : datasheet du jeu de données (format Gebru et al.).

L1 — Prétraitement et EDA linguistique

- Pipeline spaCy configurable : normalisation, remplacement des masques `XXXX` par un token spécial, segmentation, lemmatisation, POS, dépendances.
- Comparer 4 tokenizers (whitespace, spaCy, BPE GPT-2, WordPiece BERT) : taille de vocabulaire, taux d'OOV, longueur moyenne en tokens, fertilité.
- EDA : distribution des classes par année, courbes de Zipf et Heaps, top collocations par produit (PMI), lisibilité.
- Entraîner son propre tokenizer BPE sur le corpus et mesurer le gain de compression.

L2 — Baselines classiques

- Cible 1 : Product. Cible 2 : Issue. Cible 3 : « Company response » (prédire l'issue de la plainte).
- Modèles : Naive Bayes multinomial, régression logistique, SVM linéaire, LightGBM sur TF-IDF (mots + caractères).
- Recherche d'hyperparamètres (Optuna), validation croisée stratifiée, analyse des coefficients les plus discriminants par classe.

L3 — Embeddings statiques et modèles de langue

- Entraîner Word2Vec et FastText sur le corpus ; évaluer intrinsèquement (analogies métier construites à la main, similarité) et extrinsèquement (moyenne d'embeddings + LR).

- Comparer avec GloVe pré-entraîné : quelles relations sont propres au domaine financier ?
- Modèle n-gramme avec lissage Kneser-Ney : perplexité par produit, génération de texte, discussion des limites.

L4 — Deep learning « from scratch »

- Implémenter en PyTorch pur : TextCNN, BiLSTM + attention. Couches d'embedding initialisées aléatoirement vs Word2Vec (L3).
- Visualiser les poids d'attention sur des exemples.
- Sentiment : lexique VADER vs modèle transféré ; corréler le sentiment avec « Company response » et « Timely response ».
- ABSA : sentiment par aspect (frais, service client, délai, fraude).

L5 — Transformers et fine-tuning

- Implémenter un bloc transformer (self-attention multi-têtes) from scratch et vérifier sur une tâche jouet.
- Fine-tuner 3 encodeurs (DistilBERT, RoBERTa-base, DeBERTa-v3 ou ModernBERT) sur Product et Issue.
- Domain-adaptive pretraining : continuer le MLM sur 1 M de récits non étiquetés, puis fine-tuner ; mesurer le gain.
- Classification hiérarchique : tête unique vs têtes en cascade vs perte hiérarchique ; multi-label sur Tags.
- Textes longs : troncature tête/queue vs chunking + agrégation vs modèle à contexte long.
- Gestion du déséquilibre : pondération, focal loss, sur-échantillonnage ; calibration (temperature scaling, ECE).

L6 — Extraction d'information

- Schéma d'entités (8 types) : MONEY, DATE, ORG (entreprise, bureau de crédit), PRODUCT, ACCOUNT_TYPE, LAW (FCRA, FDCPA, TILA…), AGENCY, DURATION.
- Annotation de 1 500 récits ; guide d'annotation rédigé ; kappa inter-annotateurs.
- Modèles : règles + gazetteers → CRF (features manuelles) → BiLSTM-CRF → transformer token classification → LLM zero-shot. Tableau comparatif.
- Weak supervision : labeling functions pour étiqueter 50 000 récits, entraîner dessus, comparer au gold.
- Active learning : stratégie par incertitude pour choisir les prochains récits à annoter ; courbe F1 vs nombre d'exemples.

- Extraction de relations simples (ORG — a facturé — MONEY) et normalisation des montants/dates.

L7 — Thèmes, similarité, signaux faibles

- LDA et NMF (choix du nombre de thèmes par cohérence), BERTopic ; comparer qualitativement et par cohérence NPMI.
- Topics dynamiques : évolution mensuelle 2011–2026 ; détecter les thèmes émergents (ex. arnaques aux paiements instantanés, crypto).
- Recherche sémantique SBERT et clustering (HDBSCAN) ; campagnes de plaintes quasi identiques via MinHash/LSH.

L8 — Résumé automatique

- Extractif : Lead-3, TextRank. Abstractif : BART/T5 fine-tuné sur résumés silver (générés par LLM, puis filtrés) ; LLM zero-shot.
- Étudier les stratégies de décodage (beam vs nucleus, température) sur la qualité et la fidélité.
- Mesurer les hallucinations : vérification des entités du résumé dans la source (L6) + score NLI.

L9 — LLM, RAG et agent

- Base documentaire : réglementations eCFR + Ask CFPB, chunkées (taille fixe vs par section), indexées BM25 + FAISS.
- Pipeline : requête → retrieval hybride → reranking cross-encoder → génération avec citations obligatoires.
- Cas d'usage : à partir d'une plainte, produire (1) classification, (2) résumé, (3) textes réglementaires applicables, (4) projet de réponse client — en JSON validé (Pydantic).
- Fine-tuning PEFT : LoRA/QLoRA d'un petit LLM open-weight (⩽ 8 B) pour la classification générative ; comparer au classifieur L5 (qualité, coût, latence).
- Distillation : LLM étiqueteur → DistilBERT ; comparer au modèle entraîné sur labels humains.

L10 — Explicabilité, robustesse, équité

- LIME/SHAP sur L2, Integrated Gradients sur L5 ; comparer les explications.
- CheckList : invariance (changer le nom d'entreprise), tests directionnels (ajouter « fraud »), fautes de frappe.
- Dérive : performance par année sur le split temporel ; détection de dérive (PSI sur embeddings).

- Équité : écarts de performance par État et par Tag ; model card finale.

5. Architecture technique

L'architecture sépare trois couches : données versionnées, entraînement traçable, serving monitoré.

```
flowchart LR
  A[Archive CFPB ZIP] --> B[Ingestion L0 Parquet + DVC]
  R[eCFR + Ask CFPB] --> I[Index BM25 + FAISS]
  B --> C[Prétraitement L1]
  C --> D[Entraînement L2-L8 MLflow]
  D --> E[Registry modèles]
  E --> F[API FastAPI]
  I --> F
  F --> G[UI Streamlit]
  F --> H[Monitoring dérive + latence]
```

Couche	Outils
Langage, qualité	Python 3.11+, uv ou Poetry, ruff, mypy, pytest (couverture ≥ 70 % hors notebooks), pre-commit
Données	Polars/DuckDB, Parquet, DVC
NLP classique	spaCy, NLTK, scikit-learn, gensim, sklearn-crfsuite
Deep learning	PyTorch, Hugging Face Transformers, Datasets, Tokenizers, PEFT, bitsandbytes, sentence-transformers
Thèmes	gensim (LDA), BERTopic, UMAP, HDBSCAN
RAG / LLM	rank_bm25, FAISS, cross-encoder, vLLM ou Ollama pour l'inférence locale, Pydantic pour la sortie structurée
Annotation	Label Studio ou Doccano
Explicabilité	SHAP, LIME, Captum, CheckList
Suivi	MLflow ou Weights & Biases, Optuna
Serving	FastAPI, ONNX Runtime (export + quantization INT8), Docker, docker-compose

Couche	Outils
UI	Streamlit : saisie d'une plainte → classification, entités surlignées, résumé, articles cités, projet de réponse, explication SHAP
CI/CD	GitHub Actions ou GitLab CI : lint, tests, build image, évaluation de non-régression sur un jeu figé

Contraintes de calcul. GPU unique 16–24 Go (Colab Pro, Kaggle, cluster universitaire). Tout modèle doit tenir dans ce budget : QLoRA 4 bits pour les LLM, gradient checkpointing, mixed precision.

Exigences non fonctionnelles. Latence API p95 < 500 ms pour classification + NER (CPU, modèle quantifié) ; < 10 s pour la chaîne RAG complète. Reproductibilité : `make reproduce` ré-exécute un lot de bout en bout depuis les données brutes.

Arborescence du dépôt.

```
complaintlens/
  data/            # géré par DVC
  src/complaintlens/
    ingestion/ preprocessing/ features/
    models/{classic,dl,transformers,ner,topics,summarization,rag}/
    evaluation/ explainability/ serving/
  notebooks/       # un par lot, exécutables
  configs/         # Hydra
  tests/
  app/             # Streamlit
  docs/            # rapport, model cards, datasheet, guide d'annotation
```

6. Évaluation et protocole expérimental

Toute comparaison de modèles est faite sur le même split temporel figé, avec ≥ 3 seeds et un test de significativité ; un écart non significatif n'est pas un résultat.

Tâche	Métriques principales	Métriques secondaires	Seuil d'acceptation
Classification Product	Macro-F1	Accuracy, F1 par classe, matrice de confusion, ECE	≥ 0,85

Tâche	Métriques principales	Métriques secondaires	Seuil d'acceptation
Classification Issue (hiérarchique)	Macro-F1	F1 hiérarchique (hP, hR, hF), top-3 accuracy	⩾ 0,60
Prédiction Company response	Macro-F1, PR-AUC	Calibration	Battre la baseline majoritaire et TF-IDF+LR
NER	F1 entité strict (seqeval)	F1 partiel, F1 par type	⩾ 0,75
Modèles de langue	Perplexité	—	Rapport comparatif
Embeddings	Précision analogies, Spearman similarité	Performance extrinsèque	Rapport comparatif
Topics	Cohérence NPMI, c_v	Diversité des thèmes, évaluation humaine (intrusion de mots)	Rapport comparatif
Résumé	ROUGE-1/2/L, BERTScore	Fidélité (NLI, entités préservées), évaluation humaine sur 50 cas	Taux d'hallucination d'entités < 10 %
Retrieval (RAG)	Recall@k, MRR, nDCG@10	—	Recall@5 ⩾ 0,80
Génération (RAG)	Exactitude des citations, faithfulness	LLM-as-a-judge validé contre 50 jugements humains	⩾ 80 % de réponses correctement sourcées
Système	Latence p50/p95, coût par requête, taille du modèle	Débit	Voir §5

Tests statistiques. McNemar pour deux classifieurs sur le même test, bootstrap (1 000 rééchantillonnages) pour les intervalles de confiance du macro-F1, Wilcoxon sur les seeds.

Études d'ablation obligatoires. Impact du prétraitement (avec/sans lemmatisation, avec/sans token de masque), de l'initialisation des embeddings, du DAPT, de la taille des données d'entraînement (courbe d'apprentissage 1 %, 10 %, 100 %), de la stratégie de chunking du RAG, du reranker.

Analyse d'erreurs. Pour chaque modèle final : 100 erreurs catégorisées à la main (ambiguïté du label, texte trop court, erreur d'annotation d'origine, confusion taxonomique…). Estimer le taux de bruit des labels CFPB (le consommateur choisit lui-même le produit) avec cleanlab.

7. Éthique, biais, conformité

Les récits sont des allégations non vérifiées : aucun livrable ne doit présenter une plainte comme un fait établi sur une entreprise nommée.

- **Données personnelles.** Le CFPB a déjà masqué les PII, mais des fuites résiduelles existent. Pipeline de détection PII (Presidio + NER L6) appliqué avant tout affichage ; mesurer le taux de fuite résiduelle sur 500 récits.
- **Données de BNP.** Aucune donnée interne n'est utilisée ; le projet reste public et publiable.
- **Biais.** Mesurer les écarts de F1 par État et par Tag (Older American, Servicemember) ; tester l'invariance aux noms d'entreprise ; documenter les biais d'autosélection (seuls certains consommateurs se plaignent et consentent à publier).
- **LLM.** Journaliser prompts et sorties ; interdire la génération de réponses client sans citation ; afficher un avertissement « brouillon à valider par un humain ».
- **Cadre réglementaire.** Analyser le système au regard de l'AI Act européen (classification du niveau de risque, obligations de transparence) et du RGPD si transposé à des données européennes.
- **Documentation.** Model card par modèle déployé (Mitchell et al.), datasheet du corpus, guide d'annotation, bilan carbone de l'entraînement (CodeCarbon).

8. Planning, livrables, critères d'acceptation

Durée de référence : 20 semaines à temps partiel (≈ 10 h/semaine, compatible alternance), soit ≈ 200 h.

Semaines	Lot	Livrable	Critère de passage
1–2	L0	Parquet + splits DVC, datasheet	`make data` reproduit les splits à l'identique
3–4	L1	Pipeline de prétraitement testé, notebook EDA	Tests unitaires verts, comparaison des 4 tokenizers
5	L2	Baselines + rapport Optuna	Macro-F1 Product baseline documenté

Semaines	Lot	Livrable	Critère de passage
6–7	L3, L4	Embeddings, LM n-gramme, TextCNN, BiLSTM	Comparaison vs L2 avec IC bootstrap
8–10	L5	Modèles fine-tunés, DAPT, hiérarchique	Seuils §6 atteints ou écart expliqué
9–12	L6	Guide + 1 500 annotations, 5 modèles NER, courbe active learning	Kappa ⩾ 0,7, F1 ⩾ 0,75
13–14	L7	Topics statiques et dynamiques, détection de campagnes	Cohérence NPMI reportée, 3 thèmes émergents argumentés
14–15	L8	Modèles de résumé, étude du décodage	Taux d'hallucination mesuré
15–17	L9	RAG, LoRA, distillation	Recall@5 ⩾ 0,80, citations ⩾ 80 %
18	L10	Explicabilité, CheckList, dérive, équité, model cards	Rapport de robustesse complet
19	Transverse	API + UI + CI + monitoring	`docker compose up` démarre tout, CI verte
20	Final	Rapport 30–40 p, soutenance 20 min, démo live	Voir grille ci-dessous

Livrables finaux.

- [ ] Dépôt Git propre, README, licence, `make reproduce`
- [ ] Rapport scientifique (format article : état de l'art, méthodes, résultats, ablations, limites)
- [ ] Application déployée (Docker) + démo
- [ ] Datasheet, model cards, guide d'annotation, jeu annoté publié
- [ ] Tableau de bord MLflow exporté

Grille d'évaluation indicative (/20).

Critère	Points
Rigueur expérimentale (baselines, splits, tests stat, ablations)	5

Critère	Points
Couverture et maîtrise des concepts NLP	4
Qualité des résultats et analyse d'erreurs	3
Ingénierie (code, tests, reproductibilité, déploiement)	3
Éthique, explicabilité, documentation	2
Rapport et soutenance	3

Extensions pour aller au-delà du M2. Transfert cross-lingue vers des réclamations françaises (XLM-R, zero-shot) ; graphe de connaissances entreprises–produits–lois ; agent multi-outils (classification, recherche, rédaction) évalué sur tâches complètes.

9. Bibliographie et sources

Références fondamentales à citer dans l'état de l'art.

- Jurafsky & Martin, *Speech and Language Processing*, 3e éd. (draft en ligne) — manuel de référence, tous lots.
- Mikolov et al. 2013 (Word2Vec) ; Pennington et al. 2014 (GloVe) ; Bojanowski et al. 2017 (FastText) — L3.
- Kim 2014 (TextCNN) ; Lample et al. 2016 (BiLSTM-CRF) — L4, L6.
- Vaswani et al. 2017 (Transformer) ; Devlin et al. 2019 (BERT) ; He et al. 2021 (DeBERTa) — L5.
- Gururangan et al. 2020, *Don't Stop Pretraining* (DAPT) — L5.
- Ratner et al. 2017 (Snorkel, weak supervision) ; Settles 2009 (active learning survey) — L6.
- Blei et al. 2003 (LDA) ; Grootendorst 2022 (BERTopic) — L7.
- Lewis et al. 2020 (BART) ; Holtzman et al. 2020 (nucleus sampling) — L8.
- Lewis et al. 2020 (RAG) ; Hu et al. 2021 (LoRA) ; Dettmers et al. 2023 (QLoRA) — L9.
- Ribeiro et al. 2016 (LIME) ; Lundberg & Lee 2017 (SHAP) ; Sundararajan et al. 2017 (Integrated Gradients) ; Ribeiro et al. 2020 (CheckList) — L10.
- Gebru et al. 2021 (Datasheets) ; Mitchell et al. 2019 (Model Cards) — §7.

Sources consultées pour les données.

- CFPB Consumer Complaint Database Narratives Archive
- CCDB Field reference

- CFPB Ends Publication of Consumer Complaint Narratives (Consumer Finance Monitor, août 2026)
- DataLumos — CFPB Consumer Complaint Database V2